

Penerapan Spatial Autoregressive Model (SAR) dalam menentukan faktor-faktor yang memengaruhi tingkat kemiskinan di Indonesia Tahun 2024

Joshua Bryan Wijaya¹, Luthfia Aiman Hanin², Muhammad Fadhil Hakim³, Fachry Wirayuda Alindri⁴, Muhammad Bagas Ramadhan⁵, Muhammad Nur Aidi^{1†}

^{1†1}Study Program of Statistics and Data Science, IPB University, Indonesia

Abstract

Poverty is a multidimensional issue that remains a strategic challenge in Indonesia's development. Poverty data across regions often exhibit spatial dependence, where the poverty rate of a region is influenced by its neighboring regions. This study aims to identify the factors influencing the Percentage of Poor People (PPM) in 38 provinces in Indonesia in 2024 by considering spatial effects. The data used are secondary data from Statistics Indonesia (BPS). The analysis begins with classical OLS regression, which indicates the presence of spatial autocorrelation in the residuals, thus requiring a spatial regression approach. Four spatial weight matrices were compared: K-Nearest Neighbor (KNN), Radial Distance Weight (RDW), Inverse Distance Weight (IDW), and Exponential Distance Weight (EDW). Based on Moran's I statistics and model diagnostics, EDW was selected as the best weight matrix. The Lagrange Multiplier (LM) test indicated that the Spatial Autoregressive Model (SAR) is the most appropriate model. The results show that the spatial lag coefficient (ρ) is significant at 0.724, confirming a strong positive spatial dependency between provinces. The factors that significantly affect poverty are the percentage of households with their own house and the percentage of households using PLN electricity. The model satisfies the assumptions of normality and homoscedasticity, with an R-squared of 71.5%, providing a better fit than the classical model.

Keywords: Poverty, Spatial Regression, SAR, Exponential Distance Weight, Indonesia.

1. Pendahuluan

Kemiskinan merupakan isu multidimensi dan tantangan pembangunan yang kompleks di Indonesia. Upaya untuk menanggulangi dan mengurangi persentase penduduk miskin memerlukan pemahaman yang mendalam mengenai faktor-faktor penentu yang memengaruhinya (BPS, 2024). Analisis yang komprehensif sangat dibutuhkan untuk merumuskan kebijakan yang tepat sasaran dan efektif pada berbagai wilayah di Indonesia.

Data tingkat kemiskinan dan indikator sosial ekonomi yang berasal dari masing-masing provinsi di Indonesia cenderung menunjukkan adanya ketergantungan spasial (spatial dependence). Artinya, tingkat kemiskinan di suatu provinsi kemungkinan besar dipengaruhi oleh tingkat kemiskinan di provinsi-provinsi tetangganya. Hal ini juga sejalan dengan Hukum Tobler yang menyatakan bahwa segala sesuatu berhubungan dengan lainnya, tetapi hal-hal yang lebih dekat lebih terkait daripada hal-hal yang jauh (Schabenberger dan Gotway 2005). Oleh karena itu, penggunaan model regresi linear berganda konvensional menjadi kurang tepat karena dapat melanggar asumsi autokorelasi. Dalam upaya mengatasi masalah tersebut dan mendapatkan

estimasi yang lebih akurat, digunakanlah Model Regresi Spasial Autoregressive (SAR) dalam penelitian ini. Penelitian serupa telah dilakukan oleh Putri (2018), yang mana melakukan penelitian dengan pemodelan regresi spasial untuk data kasus kemiskinan Indonesia tahun 2015-2016 menggunakan SAR. Siregar (2023) melakukan penelitian serupa dengan amatan kasus kemiskinan di Sumatera Utara dengan menggunakan model Spatial Durbin model. Mempertimbangkan kemungkinan adanya efek spasial, maka metode pemecahan yang paling tepat adalah memeriksa dimensi yang disorot oleh masyarakat miskin dari masing-masing lokasi.

Penelitian ini bertujuan untuk mengidentifikasi dan menganalisis pengaruh variabel-variabel sosial ekonomi dan infrastruktur seperti akses rumah tangga ke fasilitas BAB, sanitasi, dan air bersih terhadap persentase penduduk miskin (PPM) di seluruh provinsi Indonesia dengan mempertimbangkan adanya efek spasial. Secara spesifik, penelitian ini akan melakukan pemodelan regresi SAR terhadap data Badan Pusat Statistik (BPS) tahun 2024 untuk mengestimasi koefisien pengaruh dari masing-masing peubah independen dan mengukur kekuatan ketergantungan spasial yang ada. Hasil penelitian ini diharapkan dapat memberikan wawasan yang berharga bagi pemerintah dalam merancang strategi pemberantasan kemiskinan yang efektif dan berbasis wilayah.

2. Tinjauan Pustaka

2.1 Kemiskinan

Kemiskinan merupakan kondisi tidak terpenuhinya kebutuhan dasar (makan-minum, tempat tinggal, pakaian, kesehatan) yang menjadi syarat kesejahteraan individu (Arifin, 2020). Badan Pusat Statistik tahun 2024 mengukur kemiskinan berdasarkan Garis Kemiskinan (GK), yaitu nilai pengeluaran minimum yang dibutuhkan rumah tangga untuk memenuhi kebutuhan makanan dan non-makanan dasar. GK sendiri merupakan penjumlahan dari Garis Kemiskinan Makanan (GKM) dan Garis Kemiskinan Non-Makanan (GKNM). Penduduk yang memiliki rata-rata pengeluaran perkapita perbulan di bawah GK dikategorikan sebagai penduduk miskin.

2.2 Regresi Spasial

Regresi spasial merupakan teknik statistika yang bertujuan untuk melihat hubungan peubah penjelas dengan peubah respon, dengan adanya informasi spasial pada data. Model umum regresi spasial ditunjukkan sebagai berikut:

$$y = \rho W y + X \beta + u \quad (1)$$

$$u = \lambda W u + \varepsilon \quad (2)$$

$$\varepsilon \sim N(0, \sigma^2 I)$$

dengan

y : vektor peubah respon berukuran $n \times 1$

X : matriks peubah penjelas berukuran $n \times (k+1)$

β : vektor koefisien parameter regresi yang berukuran $(k+1) \times 1$

ρ : koefisien autokorelasi spasial pada peubah respon

λ : koefisien autokorelasi spasial pada galat

u : vektor galat yang diasumsikan mengandung autokorelasi berukuran $n \times 1$

W : matriks pembobot spasial yang berukuran $n \times n$

ε : galat acak yang bebas autokorelasi berukuran $n \times 1$

Tidak adanya ketergantungan spasial terjadi jika persamaan (1) dan (2) memiliki nilai $\lambda = 1$ dan $\rho = 0$, maka model akan menjadi model regresi lasik. Model regresi spasial dapat dispesifikasi berdasarkan kesesuaiannya terhadap data. Berikut merupakan spesifikasi yang dapat dilakukan (Cahyati *et al.* 2018) :

1. Model otoregresi spasial atau *spatial autoregressive model* (SAR) adalah model yang memiliki peubah respon berkorelasi spasial. Model ini dicirikan dengan nilai $\lambda = 0$ dan $\rho \neq 0$.
2. Model galat spasial atau *spatial error model* (SEM) adalah model yang memiliki peubah galat berkorelasi spasial dengan nilai $\lambda \neq 0$ dan $\rho = 0$.
3. Model umum spasial atau *general spatial model* (GSM) dengan nilai $\lambda \neq 0$ dan $\rho \neq 0$.

2.3 Spatial Autoregressive Model (SAR)

Model otoregresif Spasial/Spatial Autoregressive Model (SAR) merupakan salah satu model spasial dengan pendekatan area yang memperhitungkan pengaruh spasial lag pada peubah respon saja. SAR terbentuk apabila $\lambda = 0$ dan $\rho \neq 0$ pada persamaan (1) sehingga persamaan model menjadi sebagai berikut:

$$\begin{aligned} \mathbf{y} &= \rho \mathbf{W} \mathbf{y} + \mathbf{X} \boldsymbol{\beta} + \mathbf{u} \\ \boldsymbol{\varepsilon} &\sim N(0, \sigma^2 \mathbf{I}) \end{aligned} \quad (3)$$

dengan $\mathbf{W}$ adalah matriks pembobot spasial dan ρ adalah koefisien otoregresi lag spasial, nilai $\boldsymbol{\varepsilon}$ diasumsikan menyebar normal, bebas, stokastik, identik, dengan nilai tengah nol dan ragam σ^2 yang menyatakan galat, dan $\boldsymbol{\beta}$ merupakan koefisien regresi. Spatial Autoregressive Model menggunakan metode kemungkinan maksimum dengan parameter yang diduga adalah $\theta = (\boldsymbol{\beta}', \rho, \sigma^2)$ sehingga model SAR dapat juga dituliskan sebagai berikut:

$$\boldsymbol{\varepsilon} = \mathbf{y} - \rho \mathbf{W} \mathbf{y} - \mathbf{X} \boldsymbol{\beta} = (\mathbf{I} - \rho \mathbf{W}) \mathbf{y} - \mathbf{X} \boldsymbol{\beta} \quad (4)$$

Fungsi *likelihood* didefinisikan sebagai fungsi kepekatan peluang bersama. Dalam hal ini, fungsi likelihood dinotasikan sebagai $L(\theta) = l(y_1, y_2, \dots, y_n | \theta)$, maka:

$$\begin{aligned} L(\theta) &= f(y_1, y_2, \dots, y_n | \theta) \\ &= f(y_1 | \theta) f(y_2 | \theta) \dots f(y_n | \theta) \\ &= \prod_{i=1}^n f(y_i | \theta) \end{aligned}$$

dengan menggunakan teorema transformasi peubah acak diperoleh fungsi kepekatan peluang bersama y sebagai berikut:

$$f(\mathbf{y} | \theta) = f(\boldsymbol{\varepsilon} | \theta) \left| \frac{\partial \boldsymbol{\varepsilon}}{\partial \mathbf{y}} \right| \quad (6)$$

Komponen galat $\boldsymbol{\varepsilon} \sim N(0, \sigma^2 \mathbf{I})$ sehingga fungsi kepekatan peluang komponen galat adalah sebagai berikut:

$$f(\varepsilon_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{\varepsilon_i^2}{2\sigma^2} \right] \quad (7)$$

Dalam hal ini, komponen galat $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ diasumsikan identik dan saling bebas satu sama lain sehingga fungsi kepekatannya adalah:

$$\begin{aligned}
f(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) &= f(\varepsilon_1)f(\varepsilon_2) \dots f(\varepsilon_n) \\
&= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{\varepsilon_1^2}{2\sigma^2}\right] \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{\varepsilon_2^2}{2\sigma^2}\right] \dots \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{\varepsilon_n^2}{2\sigma^2}\right] \\
&= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{\varepsilon_i^2}{2\sigma^2}\right] \\
&= \frac{1}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{\varepsilon'\varepsilon}{2\sigma^2}\right)
\end{aligned}$$

Selanjutnya, diperoleh fungsi likelihood bagi θ dengan melakukan substitusi fungsi kepekatan peluang galat pada rumus transformasi adalah sebagai berikut:

$$\begin{aligned}
L(\theta) &= f(\mathbf{y}|\theta) = f(\varepsilon|\theta) \left| \frac{\partial \varepsilon}{\partial \mathbf{y}} \right| \\
&= \frac{1}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{\varepsilon'\varepsilon}{2\sigma^2}\right) \left| \frac{\partial \varepsilon}{\partial \mathbf{y}} \right| \\
&= \frac{1}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{((\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2}\right) |\mathbf{I}-\rho\mathbf{W}| \\
&= \frac{|\mathbf{I}-\rho\mathbf{W}|}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{((\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2}\right)
\end{aligned}$$

Pendugaan θ dilakukan dengan memaksimumkan logaritma natural dari fungsi *likelihood* yaitu sebagai berikut:

$$\begin{aligned}
\ln(L(\theta)) &= \ln\left(\frac{|\mathbf{I}-\rho\mathbf{W}|}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{((\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2}\right)\right) \\
&= \ln|\mathbf{I}-\rho\mathbf{W}| - \frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{((\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{I}-\rho\mathbf{W})\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2}
\end{aligned}$$

Sehingga diperoleh pendugaan parameter model $\boldsymbol{\beta}$ untuk model SAR adalah sebagai berikut:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{y} - \rho\mathbf{W}\mathbf{y}) \quad (8)$$

Pendugaan nilai ρ dilakukan dengan memaksimumkan fungsi *log-likelihood* dari nilai ρ dengan melakukan iterasi numerik.

2.4 Pengaruh Spasial

Pengujian pengaruh spasial digunakan untuk menentukan model spasial yang akan terbentuk. Pengaruh spasial terhadap suatu wilayah dapat dibedakan menjadi ketergantungan spasial dan keragaman spasial. Pengaruh spasial terjadi akibat adanya korelasi antar wilayah. Uji ketergantungan spasial dapat dilakukan menggunakan uji *Lagrange Multiplier* (LM). Uji ini dilakukan untuk memilih model spasial yang tepat, yaitu menggunakan ketergantungan lag spasial, ketergantungan galat spasial, atau ketergantungan keduanya. Pengujian keragaman spasial dapat menggunakan Uji Breusch-Pagan.

2.5 Ketergantungan Spasial

Ketergantungan spasial merupakan salah satu faktor dalam mempertimbangkan menganalisa pertumbuhan ekonomi suatu wilayah. Pengujian ketergantungan spasial dapat menggunakan dengan Uji Moran. Uji Moran digunakan untuk melihat adanya autokorelasi spasial antar lokasi

amatan. Autokorelasi spasial menggambarkan pola hubungan antar lokasi/wilayah yang dapat dibedakan menjadi dua jenis, yaitu autokorelasi positif dan autokorelasi negatif. Karakteristik dari persentase penduduk miskin suatu wilayah diduga akan memengaruhi atau dipengaruhi oleh wilayah lain yang berdekatan begitu pula dengan peubah penjelas yang digunakan pada penelitian. Oleh karena itu, dilakukan pengujian karakteristik antar kabupaten/kota di Provinsi Sumatra Utara dengan menggunakan uji Moran untuk membuktikan kebenaran adanya hubungan atau ketergantungan spasial antar kabupaten/kota. Uji Moran menghasilkan suatu nilai yang disebut indeks Moran dan dinotasikan dengan nilai indeks Moran berkisar antara -1 sampai 1.

2.6 Pembobot Spasial

Matriks pembobot spasial pada dasarnya merupakan matriks yang menggambarkan hubungan antar wilayah. Setiap bobot spasial (W_{ij}), biasanya mencerminkan pengaruh spasial unit j pada unit i . Diagonal matriks W , $w_{ij} = 0$ karena diasumsikan tidak ada unit spasial yang bertetangga dengan dirinya sendiri atau tidak ada pengaruh lokasi terhadap dirinya sendiri. Penentuan nilai bobot W_{ij} ditentukan dengan dua cara yaitu berdasarkan jarak antar lokasi dan ketetanggaan. Matriks pembobot spasial yang akan digunakan pada penelitian ini adalah matriks k tetangga terdekat (*k-nearest neighbor*), *Radial Distance Weight* (RDW), *Inverse Distance Weight* (IDW), dan *Exponential Distance Weight* (EDW). Pembobotan matriks ini menggunakan informasi pada garis lintang (latitude) dan garis bujur (longitude). Matriks yang digunakan berdasarkan pada jarak centroid (d_{ij}) antar unit spasial i dan j yang didefinisikan sebagai berikut:

$$d_{ij} = \sqrt{(u_i - u_j)^2 + (v_i - v_j)^2} \quad (9)$$

dengan u_i dan u_j merupakan koordinat lintang lokasi ke- i dan koordinat lintang lokasi ke- j . Sedangkan, v_i dan v_j merupakan koordinat bujur lokasi ke- i dan koordinat bujur lokasi ke- j . Jika terdapat jarak centroid dari setiap unit spasial i terhadap unit spasial j dengan $i \neq j$ dapat diurutkan $d_{ij(1)} \leq d_{ij(2)} \leq \dots \leq d_{ij(n-1)}$. Selanjutnya, untuk setiap $k = 1, \dots, n-1$, $N_{k(i)} = \{j(1), j(2), \dots, j(k)\}$ merupakan k unit terdekat terhadap unit i . Selanjutnya, menyusun matriks pembobot C dengan elemen matriks dihitung menggunakan cara sebagai berikut:

$$C_{ij} = \begin{cases} 1, & j \in N_k(i) \\ 0, & j \text{ selainnya} \end{cases} \quad (10)$$

Formula matriks pembobot W terstandarisasi dengan rumus sebagai berikut:

$$w_{ij} = \frac{C_{ij}}{\sum_{j=1}^n C_{ij}} \quad (11)$$

Konsep pembobotan *radial distance weight* didasarkan pada fungsi radial yang memberikan bobot lebih besar pada lokasi yang lebih dekat, dan semakin kecil untuk lokasi yang lebih jauh mengikuti bentuk fungsi kernel tertentu. Semakin besar jarak antar lokasi amatan, maka bobot yang diberikan akan turun secara halus berdasarkan fungsi radial tersebut.

Konsep pembobotan dengan bobot jarak pangkat (*power distance weight*) adalah semakin jauh jarak antar lokasi amatan maka bobot yang diberikan akan semakin kecil, sehingga menyebabkan

berkurangnya pengaruh spasial seiring dengan bertambahnya jarak. Berikut cara pemberian bobot dengan metode *inverse distance weight*:

$$C_{ij} = \begin{cases} d_{ij}^{-\alpha}, i \neq j \\ 0, j \text{ selainnya} \end{cases} \quad (12)$$

Pada pembobotan *exponential distance weight*, pengaruh spasial antar lokasi berkurang secara eksponensial seiring bertambahnya jarak. Parameter $\alpha > 0$ mengontrol tingkat penurunan bobot. Semakin besar α , semakin cepat bobot mengecil akibat jarak. Rumus pemberian bobot menggunakan metode EDW dituliskan sebagai berikut:

$$C_{ij} = \begin{cases} e^{-\alpha d_{ij}}, i \neq j \\ 0, j \text{ selainnya} \end{cases} \quad (13)$$

dimana d_{ij} adalah jarak antara lokasi i dan j serta nilai α merupakan bilangan bulat positif yang dalam penelitian ini menggunakan $\alpha = 1$. Jarak yang digunakan sebagai standar pada matriks pembobot *radial distance weight* dalam penelitian ini adalah 200 kilometer. Kemudian matriks C distandarisasi baris menggunakan persamaan (11).

3. Metodologi

3.1 Data

Penelitian ini menggunakan data sekunder yang berasal dari Badan Pusat Statistik (BPS) pada tahun 2024. Indonesia terdiri atas 38 provinsi. Penjelasan mengenai peubah yang digunakan dapat dilihat pada Tabel 1.

Peubah	Nama Peubah	Satuan	Referensi
Y	Persentase penduduk miskin	%	Putri CA (2018)
X1	Persentase rumah tangga yang memiliki rumah sendiri	%	Putri CA (2018)
X2	Persentase rumah tangga yang tidak memiliki fasilitas BAB	%	Putri CA (2018)
X3	Persentase rumah tangga yang memiliki kemampuan akses air minum layak	%	Putri CA (2018)
X4	Persentase rumah tangga yang mampi mengakses sanitasi layak	%	Putri CA (2018)
X5	Persentase rumah tangga yang menggunakan listrik PLN	%	Putri CA (2018)
X6	Kepadatan penduduk	Jiwa/ km^2	Putri CA (2018)
X7	Tingkat pengangguran terbuka	%	Ayudia dan Putri (2024)

3.2 Metode

Analisis data dilakukan dengan menggunakan software R 4.5.0. Berikut merupakan tahapan analisis yang digunaakn pada penelitian ini.

1. Melakukan eksplorasi data untuk melihat karakteristik data secara umum, meliputi sebaran peubah respon dan korelasi antar peubah

2. Pendeteksian Multikolinearitas

Melakukan pendeteksian multikolinearitas untuk mengetahui adanya korelasi antara dua peubah penjelas atau lebih dengan menggunakan Variance Inflation Factor (VIF). Rumus untuk menghitung VIF adalah sebagai berikut:

$$VIF_p = \frac{1}{1 - R_p^2} \quad (14)$$

Dengan R_p^2 adalah koefisien determinasi antara X_p dengan peubah penjelas lainnya. Jika $VIF > 10$, maka peubah tersebut terindikasi mengalami multikolinearitas.

3. Identifikasi pencilan, titik leverage, dan amatan berpengaruh menggunakan nilai hii, ri, dan DFFITS. DFFITS mengukur jumlah penghapusan kasus ke-i dari analisis yang dapat mengubah nilai prediksi kasus ke-1.
4. Mengidentifikasi kedekatan antar wilayah dengan membentuk matriks pembobot spasial. Matriks pembobot spasial disusun dengan menggunakan matriks k tetangga terdekat (*k-nearest neighbor*), *radial distance weight*, *inverse distance weight*, dan *exponential distance weight*. Matriks pembobot spasial yang dipilih adalah matriks dengan nilai indeks moran optimum dan *p-value* terkecil.
5. Melakukan regresi linear berganda dengan metode pendugaan kuadrat terkecil (MKT).
6. Melakukan uji dugaan parameter menggunakan uji F dan uji t-parsial.
7. Melakukan seleksi peubah menggunakan metode *best subset selection*. Model terbaik dipilih berdasarkan AIC, Cp Mellow's, terkecil dan adjusted R2 terbesar.
8. Melakukan uji asumsi terhadap pemodelan regresi linear berganda hasil seleksi peubah, diantaranya uji formal dan nonformal untuk asumsi nilai harapan sisaan, normalitas, homogenitas ragam, dan sisaan yang saling bebas
 - a. Uji nilai harapan sisaan sama dengan nol menggunakan uji t untuk menunjukkan bahwa peubah respon pada model hanya dipengaruhi oleh peubah penjelas yang diteliti sehingga didapatkan estimasian model regresi yang tidak bias.
 - b. Uji normalitas menggunakan uji *Shapiro-Wilk*. Statistik uji W selalu memenuhi $0 < W \leq 1$, untuk nilai W yang cukup dekat dengan 1 (tergantung pada jumlah peubah x) atau jika nilai p kurang dari α , menandakan bahwa sisaan tidak menyebar normal.
 - c. Uji homoskedastisitas menggunakan uji *Breusch-Pagan-Godfrey*. Uji ini digunakan untuk mendeteksi apakah terdapat ketidakhomogenan ragam dari sisaan pada model regresi. Jika heteroskedastisitas terjadi, maka ragam sisaan tidak konstan sehingga dapat menyebabkan estimasian parameter yang tidak efisien.
 - d. Uji autokorelasi menggunakan uji *Durbin-Watson*. Autokorelasi yang terjadi akan menyebabkan estimasi koefisien regresi menjadi tidak efisien dan uji hipotesis menjadi tidak valid.
9. Memeriksa keberadaan autokorelasi spasial dengan menggunakan uji Moran (global dan lokal) dengan hipotesis sebagai berikut:
 $H_0: I = 0$ (tidak ada autokorelasi spasial)
 $H_1: I \neq 0$ (ada autokorelasi spasial)
Formula indeks moran yaitu sebagai berikut:

$$I = \frac{n \sum_{i=1}^n \sum_{j \neq i=1}^n W_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^n \sum_{j=1}^n W_{ij} (x_i - \bar{x})} \quad (15)$$


Dengan I merupakan indeks moran, n adalah banyaknya wilayah dalam hal ini sebanyak 38 provinsi, W_{ij} merupakan elemen matriks pembobot spasial pada baris ke- i dan ke- j . x_i merupakan nilai pengamatan pada wilayah ke- i , $\bar{x}$ adalah rata-rata nilai pengamatan.

10. Apabila terdapat autokorelasi spasial, maka selanjutnya dilakukan uji ketergantungan spasial dengan menggunakan uji *Lagrange Multiplier* (LM). Jika terdapat ketergantungan spasial pada peubah respon maka dibentuk model SAR.
11. Membentuk model regresi spasial yang sesuai dengan hasil uji LM. Estimasi koefisien model SAR dilakukan dengan metode kemungkinan maksimum.
12. Mengukur kebaikan model menggunakan *R-squared* dan jumlah peubah penjelas yang signifikan terhadap respon.
13. Melakukan pengujian asumsi pada model SAR, yakni uji normalitas menggunakan uji Anderson-Darling, homogenitas ragam menggunakan uji Breusch-Pagan, dan uji autokorelasi spasial menggunakan indeks moran.

4. Hasil dan Pembahasan

4.1 Eksplorasi Data


Pada Kamis 17 November 2022, Indonesia resmi mengalami pemekaran jumlah provinsi kembali sehingga memiliki total 38 provinsi. Persentase kemiskinan tiap provinsi di Indonesia tahun 2024 ditunjukkan oleh boxplot dan diagram batang. Gambar 1(a) menyatakan bahwa terdapat 2 provinsi dengan tingkat kemiskinan yang teridentifikasi sebagai pencilan, yakni Provinsi Papua Pegunungan dengan persentase kemiskinan sebesar 32.97% dan Provinsi Papua Tengah dengan persentase sebesar 29.76%. Sebaliknya, Provinsi Bali menjadi provinsi dengan persentase kemiskinan terkecil, yakni sebesar 4%.



Gambar 1: Distribusi persentase kemiskinan dengan (a) diagram kotak garis (b) diagram batang


Rata-rata kemiskinan dari berbagai provinsi di Indonesia adalah sebesar 11.15%, dimana pada gambar 1(b), terlihat ada 15 provinsi yang memiliki nilai persentase kemiskinan di atas rata-rata,

yakni Provinsi Sulawesi Barat, Sulawesi Tenggara Sulawesi Tengah, NTB, Bengkulu, Aceh, Gorontalo, Maluku, Papua, Papua Selatan, Papua Barat Daya, NTT, Papua Barat, Papua Tengah, dan Papua Pegunungan. Selanjutnya Gambar 2 menunjukkan peta tematik (*Choropleth map*) untuk melihat persentase penduduk miskin dengan menggunakan warna. Terlihat bahwa tingkat kemiskinan di Indonesia terpusat di Pulau Papua, sehingga penting bagi pemerintah untuk memusatkan bantuan pada provinsi-provinsi di Pulau Papua. Selain itu, hampir setiap Provinsi memiliki warna yang sama dengan provinsi perbatasannya. Hal ini mengindikasikan persentase penduduk miskin di satu daerah cenderung mendekati persentase penduduk miskin di daerah lain.



Gambar 2: Peta tematik penduduk miskin di Indonesia 2024

Plot korelasi yang disajikan pada gambar 3 menggambarkan bahwa peubah akses sanitasi layak (X4) dan peubah rumah tangga yang menggunakan listrik PLN (X5) memiliki hubungan negatif kuat terhadap persentase kemiskinan (Y) bersamaan dengan peubah rumah tangga yang mampu mengakses air minum (X3), kepadatan penduduk (X7), dan tingkat pengangguran terbuka (TPT) yang juga berkorelasi negatif dengan Y, hal ini berarti provinsi yang banyak memiliki rumah tangga dengan akses sanitasi layak dan menggunakan listrik PLN cenderung memiliki tingkat kemiskinan yang rendah. Sebaliknya, peubah rumah tanpa fasilitas BAB (X2) memiliki hubungan positif kuat terhadap persentase kemiskinan (Y), bersamaan dengan peubah rumah tangga dengan kepemilikan rumah sendiri (X1), hal ini berarti provinsi dengan rumah tangga yang tidak memiliki fasilitas BAB cenderung memiliki tingkat kemiskinan yang tinggi. Peubah X2 dan X4 memiliki korelasi diatas 0.9 dengan peubah penjelas lainnya, hal ini dapat menjadi risiko timbulnya multikolinearitas dalam model.



Gambar 3: Plot korelasi antar peubah

4.2 Pengujian Multikolinearitas

Pendeteksian multikolinearitas dilakukan dengan menghitung nilai VIF (*Variance Inflation Factor*) tiap peubah penjelas X. Adanya multikolinearitas dalam model RLB ditandai dengan nilai $VIF > 10$. Hasil pengujian skor VIF dapat dilihat pada Tabel 1.

Tabel 1: Hasil uji VIF

Nilai VIF						
X1	X2	X3	X4	X5	X6	X7
2.26	9.79	3.19	16.56	9.84	1.67	1.91


Tabel 1 menunjukkan bahwa peubah X4 (Rumah tangga dengan akses sanitasi layak) memiliki nilai $VIF > 10$, sehingga terdapat multikolinearitas dalam model RLB. Untuk menangani hal ini, maka peubah X4 dihapus dari model, karena dapat diwakilkan dengan peubah X3 (Rumah tangga dengan akses air minum bersih). Skor VIF setelah penghapusan peubah X4 dapat dilihat pada Tabel 2 berikut.

Tabel 2 : Hasil uji VIF setelah peubah X4 dihapus

Nilai VIF					
X1	X2	X3	X5	X6	X7
2.25	6.10	2.67	6.96	1.65	1.61

4.3 Pendeteksian Pencilan, Titik Leverage, dan Amatan Berpengaruh

Pada gambar 4, ditunjukkan adanya amatan yang terdeteksi sebagai pencilan dan titik *leverage*. Provinsi Jambi terdeteksi sebagai pencilan dan amatan berpengaruh. Provinsi Sulawesi Tengah, Sulawesi Tenggara, dan DKI Jakarta terdeteksi sebagai titik *leverage* dan amatan berpengaruh. Kemudian, Provinsi Jawa Tengah dan Kalimantan Tengah terdeteksi sebagai amatan berpengaruh.



Gambar 4 : Hasil pendeteksian pencilan, titik *leverage*, dan amatan berpengaruh

4.4 Pemodelan Awal

Nilai-p hasil uji simultan menggunakan uji F bernilai 0.006, yang berarti $< \alpha$ sebesar 0.05. Hasil uji simultan ini menunjukkan bahwa peubah penjelas X1, X2, X3, X5, X6, dan X7 berpengaruh signifikan pada taraf nyata 5%. Hasil pemodelan dapat dilihat pada Tabel 2.

Tabel 2: Pemodelan awal regresi

Peubah	Koefisien	nilai p
Intercept	2.979	0.486
X1	0.609	0.198
X2	0.817	0.380
X3	0.435	0.209
X5	-1.063	0.007*
X6	-0.053	0.812
X7	1.187	0.587

Kebaikan model yang dilihat dari nilai *adjusted R-squared* yang sudah cukup baik, yaitu sebesar 63.81%, dimana terdapat satu peubah yang signifikan terhadap peubah respon, yakni peubah X5 (Rumah tangga yang menggunakan listrik PLN). Namun, peubah X3 dan X7 mengalami peubahan tanda, yang semula X3 dan X7 berhubungan negatif terhadap Y sekarang justru menjadi positif. Hal ini menjadi indikasi adanya pelanggaran asumsi dalam model yang telah dibuat.

4.5 Pemilihan Model Terbaik berdasarkan nilai AIC, CP Mellow's, *adusted R*²

Model terbaik dipilih menggunakan metode *best subset selection*. Model yang akan dibentuk adalah sejumlah 2^k model, dengan k adalah banyaknya peubah penjelas. Terdapat 6 peubah penjelas dalam penelitian ini, sehingga banyaknya model yang dibandingkan adalah 64 model. Model terbaik dari setiap n jumlah peubah penjelas dapat dilihat pada Tabel 3.

Tabel 3 : Perbandingan model terbaik dengan n peubah penjelas

Indeks	Peubah Penjelas	<i>Adj R</i> ²	AIC	C(p)
1	X5	0.634	218.649	2.383
2	X1 + X5	0.653	217.594	1.572*
3	X1 + X3 + X5	0.658	217.889	2.099
4	X1 + X2 + X3 + X5	0.656	219.050	3.398
5	X1 + X2 + X3 + X5 + X7	0.649	220.635	5.058
6	X1 + X2 + X3 + X5 + X7	0.638	222.564	7.000

Tabel 3 menunjukkan bahwa AIC (*Akaike's Information Criterion*) yang dihasilkan pada setiap model memiliki nilai yang berbeda. Nilai AIC, nilai CP Mellow's terkecil dan adjusted R² terbedar ditunjukkan pada model dengan index kedua, yaitu model yang terdiri dari dua peubah

penjelas, yakni rumah tangga dengan kepemilikan rumah sendiri (X1) dan rumah tangga yang menggunakan PLN (X5).

4.6 Pemodelan setelah seleksi peubah

Nilai-p hasil uji simultan menggunakan uji F bernilai 0.000*, yang berarti $< \alpha$ sebesar 0.05. Hasil uji simultan ini menunjukkan bahwa peubah penjelas X1 dan X5 berpengaruh signifikan pada taraf nyata 5%. Hasil pemodelan dapat dilihat pada Tabel 2.

Tabel 2: Pemodelan awal regresi

Peubah	Koefisien	nilai p
Intercept	26.358	0.004*
X1	0.144	0.096
X5	-0.297	0.000*

Kebaikan model yang dilihat dari nilai *adjusted R-squared* yang sudah cukup baik, yaitu sebesar 65.29% (meningkat 1.48%), dimana terdapat satu peubah yang signifikan terhadap peubah respon, yakni peubah X5 (Rumah tangga yang menggunakan listrik PLN). Hubungan peubah X1 dan X5 juga sudah sesuai dengan matriks korelasi.

4.7 Uji asumsi

Asumsi pada model regresi linear berganda dapat dilakukan dengan uji formal maupun non-formal. Uji formal dilakukan melalui uji *Shapiro-Wilk*, *Breusch-Pagan*, dan uji *Durbin Watson*. Hasil uji asumsi berupa uji nilai harapan sisaan, normalitas, uji homoskedastisitas, dan uji autokorelasi terdapat pada Tabel 3.

Tabel 3: Hasil uji asumsi pemodelan setelah seleksi peubah

Asumsi	Uji	Nilai p	Kesimpulan
$E[\varepsilon_i] = 0$	<i>t-test</i>	1	Terpenuhi
Normalitas	<i>Shapiro-Wilk test</i>	0.213	Terpenuhi
Homoskedastisitas	<i>Breusch-Pagan test</i>	0.836	Terpenuhi
Keacakan sisaan	<i>Durbin-Watson test</i>	0.045	Tidak Terpenuhi


Pada taraf nyata 5%, asumsi yang diperlukan model hampir seluruhnya terpenuhi. Asumsi sisaan saling bebas pada regresi gagal terpenuhi, karena nilai-p hasil uji *durbin watson* bernilai 0.045 (< 0.05). Hal ini menunjukkan bahwa residual model saling berkorelasi, namun belum diketahui, bentuk korelasi yang terjadi maupun amatan yang terlibat dalam korelasi tersebut.

4.8 Deteksi Autokorelasi Spasial

4.8.1 Matriks pembobot dan ketetanggaan antar wilayah

Langkah fundamental dalam mengidentifikasi autokorelasi spasial, baik secara global maupun lokal, adalah mendefinisikan secara formal hubungan ketetanggaan antar wilayah observasi. Hubungan ini dikuantifikasi melalui matriks pembobot spasial (*Spatial Weights Matrix*), yang

menjadi dasar untuk mengukur sejauh mana nilai di suatu lokasi dipengaruhi oleh nilai di lokasi sekitarnya. Penelitian ini akan menggunakan beberapa jenis matriks pembobot spasial, yakni matriks k tetangga terdekat (k -nearest neighbor), *Radial Distance Weight* (RDW), *Inverse Distance Weight* (IDW), dan *Exponential Distance Weight* (EDW). Ketetanggaan antar wilayah berdasarkan matriks pembobotnya dapat terlihat pada Gambar 5.



Gambar 5: Matriks pembobot dengan metode (a) knn ($k=3$) (b) *radial distance weight* ($r = 200$ km²) (c) *inverse distance weight* (d) *exponential distance weight*

Metode *radial distance weight* menunjukkan hampir setiap provinsi seakan-akan bertetangga. Hal ini dikarenakan radius yang ditetapkan sangat besar, yakni 200 km². Metode berbasis kedekatan (*Contiguity Based*) tidak digunakan mengingat terdapat pemisah berupa laut pada beberapa provinsi, sehingga akibat pemisah berupa laut itulah, terdapat beberapa provinsi yang tidak memiliki tetangga. Hasil spesifik terkait ketertanggaan antar wilayah berdasarkan matriks pembobotnya dapat dilihat pada Tabel 4.

Tabel 4 : Perbandingan ketetanggaan antar wilayah berdasarkan matriks pembobot

Index	Matriks Pembobot	Jumlah <i>Link</i>	Rasio	Rataan
1	K-Nearest Neighbor ($k=3$)	114	8.08%	3
2	Radial Distance Weight ($r = 200$ km ²)	1406	97.37%	37
3	Inverse Distance Weight ($a = 1$)	212	15.08%	4
4	Exponential Distance Weight ($a = 1$)	195	13.87%	1

Metode *exponential distance weight* (EDW) menjadi pilihan paling tepat karena mampu menghasilkan struktur ketetanggaan yang realistis untuk konteks kepulauan Indonesia. Bobot antarwilayah menurun sangat cepat seiring jarak sehingga provinsi yang jauh tidak dipaksakan bertetangga seperti pada KNN, namun juga tidak menimbulkan *over-connectivity* ekstrem seperti

radial distance weight. Tidak seperti IDW yang masih memberi pengaruh cukup besar pada wilayah jauh, EDW menjaga hubungan spasial tetap fokus pada kedekatan relevan tanpa menciptakan *noise*, sehingga pola dependensi spasial lebih stabil, natural, dan secara teoritis paling menggambarkan dinamika sosial-ekonomi antarprovinsi. Oleh karena itu, untuk uji autokorelasi global dan lokal, selanjutnya akan digunakan matriks pembobot EDW.

4.8.2 Uji Autokorelasi Spasial Global (Moran's I)

Uji Moran's I dilakukan terhadap peubah respon (Y), peubah penjelas (X1 dan X5), serta pada sisaan (*residual*) untuk mendeteksi korelasi spasial pada setiap peubah dan pada sisaan model secara global. Matriks pembobot yang digunakan adalah matriks *exponential distance weight* (EDW). Hasil uji autokorelasi global dapat terlihat pada Tabel 5.

Tabel 5: Hasil uji Moran's I

Amatan	Indeks Moran (I)	Nilai p	Standar deviasi	keputusan
Y	0.191	0.000	12.130	Terdapat autokorelasi positif
X1	-0.026	0.973	0.034	Tidak terdapat autokorelasi
X5	0.141	0.000	11.025	Terdapat autokorelasi positif
sisaan	0.025	0.005	2.759	Terdapat ketergantungan spasial dalam model

Berdasarkan hasil pada Tabel 5, nilai moran's I pada peubah respon persentase kemiskinan bernilai 0.191 dengan nilai $p < 0.05$, hal ini menunjukkan pada taraf nyata 5%, persentase kemiskinan menunjukkan indikasi keberadaan autokorelasi positif, dimana daerah dengan persentase kemiskinan tinggi cenderung bertetangga dengan daerah dengan persentase kemiskinan tinggi juga, berlaku sebaliknya. Hal ini juga berlaku pada peubah X5 (persentase rumah tangga yang menggunakan listrik PLN). Namun, pada peubah X1 tidak terdeteksi adanya autokorelasi.

Nilai moran's I pada sisaan (*residual*) model OLS menunjukkan nilai moran's I sebesar 0.025 dan nilai $p < 0.05$. Hal ini menunjukkan bahwa asumsi "kebebasan antar pengamatan" yang dilanggar pada uji asumsi sebelumnya terjadi karena terdapat ketergantungan spasial antar amatan.

4.8.3 Uji Autokorelasi Spasial Lokal (LISA)

Secara global, terdapat autokorelasi spasial positif pada peubah respon (persentase kemiskinan). Untuk mengetahui lokasi spesifik yang signifikan menyumbang autokorelasi tersebut, dilakukan uji autokorelasi spasial lokal menggunakan Local Indicators of Spatial Association (LISA). Pada tahap ini, analisis tetap dilakukan dengan matriks pembobot *exponential distance weight*. Hasil uji autokorelasi secara lokal dapat dilihat pada Tabel 6.

Tabel 6 : Hasil uji autokorelasi lokal

Klaster	Jumlah Wilayah	Provinsi
High-High (<i>Hotspot</i>)	11	Sulawesi Tengah, Papua Tengah, Papua Barat, Gorontalo, Papua Selatan, Maluku, Papua, Papua Barat Daya, Sulawesi Tenggara, Nusa Tenggara Timur (NTT), Papua Pegunungan,
High-Low (<i>Outlier</i>)	4	Sulawesi Barat, Bengkulu, Nusa Tenggara Barat (NTB), Aceh
Low-Low (<i>Coldspot</i>)	20	Riau, Daerah Istimewa Yogyakarta (DIY), Sumatera Barat, DKI Jakarta, Lampung, Kepulauan Riau, Jambi, Bali, Jawa Timur, Sumatera Utara, Kalimantan Selatan, Kalimantan Tengah, Kepulauan Bangka Belitung, Sumatera Selatan, Banten, Kalimantan Utara, Kalimantan Timur, Jawa Tengah, Kalimantan Barat, Jawa Barat.
Low-High (<i>Outlier</i>)	3	Sulawesi Selatan, Sulawesi Utara, Maluku Utara
Tidak signifikan	0	-



Gambar 6 : Peta klasterisasi LISA pada peubah persentase kemiskinan

Klaster *High-High* merupakan lokasi dengan nilai tinggi yang dikelilingi oleh lokasi dengan nilai tinggi. Klaster *Low-Low* merupakan lokasi dengan nilai rendah yang dikelilingi oleh lokasi dengan nilai rendah. Sedangkan untuk klaster *Low-High* merupakan lokasi dengan nilai rendah yang dikelilingi lokasi dengan nilai tinggi dan berlaku sebaliknya untuk klaster *High-Low*. Gambar 6 menunjukkan ilustrasi dari Tabel 6.

4.8.4 Uji *Lagrange Multiplier (LM test)*

Uji Morans's I dilakukan untuk mengetahui adanya efek spasial, uji ini dilakukan dengan *exponential distance weight* (EDW) sebagai matriks pembobotnya. Sebelumnya, Uji Moran's I menunjukkan adanya autokorelasi spasial antar wilayah, maka uji dapat diteruskan untuk melakukan uji *Lagrange Multiplier*. Hasil uji LM dapat dilihat pada Tabel 7.

Tabel 7 : Hasil uji *lagrange multiplier*

Model	Nilai p
LM Lag (SAR)	0.008*
LM Error (SEM)	0.559

Berdasarkan Tabel 7, model regresi spasial yang signifikan dengan tingkat signifikansi 5% yaitu model spasial lag (SAR) dimana nilai $p < \alpha$, sedangkan model spasial error (SEM) tidak signifikan karena $p\text{-value} > \alpha$, sehingga akan dilanjutkan ke dalam pemodelan spasial lag (SAR).

4.9 Pemodelan SAR

4.9.1 Hasil dan interpretasi model

Berdasarkan uji asumsi model OLS (Autokorelasi tidak terpenuhi), uji autokorelasi spasial, dan uji dependensi spasial (ketergantungan spasial), pemodelan SAR layak digunakan untuk pemodelan peubah respon persentase kemiskinan di Indonesia. Pemodelan dilakukan dengan taraf nyata 5%. Hasil pemodelan menggunakan SAR dapat dilihat pada Tabel 8.

Tabel 8: Pemodelan SAR

Peubah	Koefisien	nilai p
Intercept	12.542	0.126
X1	0.161	0.029*
X5	-0.245	0.000*
ρ	0.724	0.019*

Nilai-p hasil uji simultan menggunakan uji F bernilai 0.000*, yang berarti $< \alpha$ sebesar 0.05. Hasil uji simultan ini menunjukkan bahwa peubah penjelas X1 dan X5 berpengaruh signifikan pada taraf nyata 5%. Kebaikan model yang dilihat dari nilai *R-squared* yang sudah cukup baik, yaitu sebesar 71.53%, dimana seluruh peubah signifikan terhadap peubah respon, yakni peubah X1 (Persentase rumah tangga yang memiliki rumah sendiri) dan X5 (persentase rumah tangga yang menggunakan listrik PLN). Hubungan peubah X1 dan X5 juga sudah sesuai dengan matriks korelasi. Melalui pemodelan SAR, diperoleh nilai koefisien lag (ρ) sebesar 0.724 dan berpengaruh signifikan terhadap peubah respon, hal ini berarti terdapat efek positif yang signifikan dari kemiskinan di area tetangga pada kemiskinan di area observasi. Melalui Tabel 8, diperoleh persamaan:

$$\widehat{E(Y)} = 12.542 + 0.161X1 - 0.245X5$$

Peubah Persentase rumah tangga yang memiliki rumah sendiri (X1) memiliki koefisien bernilai positif yakni 0.161 (hasil ini sudah sesuai matriks korelasi). Peubah X1 berpengaruh signifikan terhadap persentase kemiskinan di Indonesia, yang berarti, jika terjadi peningkatan 1% pada rumah tangga yang memiliki rumah sendiri, maka akan meningkatkan nilai dugaan rata-rata

tingkat kemiskinan sebesar 0.161%. Hasil ini sesuai dengan hasil penelitian sebelumnya, dimana persentase rumah tangga yang memiliki rumah sendiri berpengaruh positif terhadap tingkat kemiskinan (Putri 2018).

Kemudian, persentase rumah tangga yang menggunakan listrik PLN (X5) memiliki koefisien bernilai negatif yakni -0.245 (hasil ini sesuai matriks korelasi). Peubah X5 berpengaruh signifikan terhadap persentase kemiskinan di Indonesia, yang berarti, jika terjadi peningkatan 1% pada rumah tangga yang menggunakan listrik PLN, maka akan menurunkan nilai dugaan rata-rata tingkat kemiskinan sebesar 0.245%. Hasil ini sesuai dengan hasil penelitian sebelumnya, dimana persentase rumah tangga yang menggunakan listrik PLN berpengaruh negatif terhadap tingkat kemiskinan (Putri 2018).

4.9.2 Uji asumsi pemodelan SAR

Model OLS belum memenuhi asumsi sisaan saling bebas. Hal tersebut dikarenakan terdapat autokorelasi spasial pada peubah respon yang sudah dibuktikan melalui uji Moran's I. Selanjutnya, akan diperiksa *residual* model SAR untuk memenuhi asumsi yang diperlukan dalam inferensi parameter regresi. Hasil uji asumsi model SAR dapat dilihat pada Tabel 9.

Tabel 9 : Uji asumsi model SAR

Asumsi	Uji	Nilai p	Kesimpulan
$E[\varepsilon_i] = 0$	<i>t-test</i>	1	Terpenuhi
Normalitas	<i>Anderson-Darling test</i>	0.213	Terpenuhi
Homoskedastisitas	<i>Breusch-Pagan test</i>	0.836	Terpenuhi
Keacakan sisaan	<i>Moran's I test</i>	0.4198	Terpenuhi

4.9.3 Perbandingan Model OLS dan SAR

Pemodelan dengan OLS (*Ordinary Least Square*) dan SAR(*Spatial Autoregressive*) yang sudah dilakukan selanjutnya akan dibandingkan berdasarkan besaran AIC, R^2 , jumlah peubah penjelas yang signifikan, serta asumsi yang telah dipenuhi oleh kedua model. Model terbaik memiliki AIC terkecil serta R^2 dan jumlah peubah penjelas yang signifikan terbesar. Perbandingan kedua model dapat dilihat pada Tabel 10.

Tabel 10: Perbandingan model OLS dan SAR

Model	AIC	R^2	n signifikan	Normalitas	Homogenitas	Sisaan saling bebas
OLS	217.594	65.29%	1	Terpenuhi	Terpenuhi	Tidak Terpenuhi
SAR	214.17	71.53%	2	Terpenuhi	Terpenuhi	Terpenuhi

Pada data dengan autokorelasi dan dependensi spasial di peubah responnya, terbukti model regresi dengan *Spatial Autoregressive* (SAR) memiliki performa yang lebih unggul dibandingkan model regresi dengan *Ordinary Least Square* (OLS). Hal ini dikarenakan, pemodelan SAR mampu menangkap efek lag dari nilai peubah respon di wilayah tetangga terhadap wilayah observasi.

5. Kesimpulan dan Saran

Data persentase penduduk miskin di Indonesia memiliki autokorelasi spasial yang kuat, sehingga model regresi konvensional tidak memadai. Melalui serangkaian pengujian, termasuk pemilihan matriks pembobot spasial, deteksi autokorelasi spasial global dan lokal, serta uji dependensi spasial, diperoleh bahwa *Exponential Distance Weight* (EDW) merupakan matriks pembobot terbaik dan *Spatial Autoregressive Model* (SAR) adalah model yang paling sesuai untuk menangkap karakteristik data. Hasil pemodelan SAR menunjukkan adanya efek spasial yang signifikan ($p = 0.724$), menandakan bahwa tingkat kemiskinan di suatu provinsi dipengaruhi oleh provinsi di sekitarnya.

Secara substantif, dua faktor signifikan yang memengaruhi tingkat kemiskinan adalah persentase rumah tangga yang memiliki rumah sendiri (X1) dan persentase rumah tangga yang menggunakan listrik PLN (X5). Peubah X1 berpengaruh positif, menunjukkan bahwa kepemilikan rumah tidak selalu identik dengan kesejahteraan, sementara X5 berpengaruh negatif, menegaskan bahwa akses terhadap infrastruktur dasar (khususnya listrik) berperan penting dalam menurunkan kemiskinan. Model SAR memberikan performa yang lebih baik daripada model OLS dengan nilai R-squared sebesar 71.53%, AIC yang lebih kecil, serta seluruh asumsi model yang terpenuhi, sehingga model ini dapat digunakan sebagai dasar analisis yang lebih akurat.

Berdasarkan temuan tersebut, pemerintah disarankan untuk merancang intervensi berbasis wilayah dengan memperhatikan pola ketergantungan spasial, terutama pada kluster *High-High* yang menjadi kantong kemiskinan nasional, seperti provinsi-provinsi di Pulau Papua dan sebagian wilayah Sulawesi. Peningkatan akses infrastruktur dasar, khususnya listrik dan layanan sanitasi yang layak, perlu diprioritaskan sebagai strategi percepatan penurunan kemiskinan. Selain itu, penelitian selanjutnya dapat memperluas cakupan variabel atau menggunakan model spasial lain seperti SDM atau GWR untuk menangkap keragaman spasial yang lebih kompleks.

Daftar Pustaka

- Arifin, J. 2020. *Budaya kemiskinan dalam penanggulangan kemiskinan di Indonesia*. Sosio Informa. 6(2):114–132. <https://doi.org/10.33007/inf.v6i2.2372>.
- Badan Pusat Statistik Indonesia. 2024. *Data dan Informasi Kemiskinan Kabupaten/Kota Tahun 2024*. Jakarta: Badan Pusat Statistik Indonesia.
- Cahyati, R., Djuraidah, A., & Rahardiantoro, S. 2018. Pemodelan regresi spasial kekar: Studi kasus jumlah kunjungan wisatawan mancanegara asal Eurasia di Indonesia tahun 2015. *Xplore: Journal of Statistics*. 2(1):61–70. doi:10.29244/xplore.v2i1.85.

- Putri, C. A. 2018. *Spatial Autoregressive Model (SAR) pada Kasus Kemiskinan Indonesia Tahun 2015–2016*. Skripsi. Departemen Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Institut Pertanian Bogor, Bogor.
- Schabenberger, O., & Gotway, C. A. 2005. *Statistical Methods for Spatial Data Analysis*. Chapman & Hall/CRC.
- Siregar, A. L. 2023. *Penerapan Spatial Durbin Model dalam Menentukan Faktor yang Memengaruhi Kemiskinan di Provinsi Sumatera Utara*. Skripsi. Departemen Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Institut Pertanian Bogor, Bogor.